

# 비트코인 상승/하락 시계열 분류 예측

Recsys-10조(물어봐조)

곽정무, 박준하, 박태지, 신경호, 이효준

## 1. 프로젝트 개요

### 1-1. 개요

2023년 1시간 단위로 현재 행 시점에서 1시간 뒤 비트코인 가격이 -0.5% 이상 하락한 경우 0, -0.5 ~ 0 미만 1, 0 ~ 0.5 미만 2, 그리고 0.5 이상 상승한 경우 3으로 레이블링 되어있는 데이터를 학습하여 2024년 1월부터 4월까지 1시간 단위로 다음 1시간 뒤 등락률이 0, 1, 2, 그리고 3 중 어느 곳에 속할지 정확히 예측하는 것이 대회의 목적이다.

데이터는 크게 마켓 데이터와 네트워크 데이터가 주어졌다. 마켓 데이터는 가상 화폐 거래소별 생성되는 지표로서 시장과 관련된 데이터를 포함하고 네트워크 데이터는 비트코인이 블록체인을 활용하는 만큼 블록체인 내에서 생성되는 지표를 포함하고 있다. 마켓 데이터는 거래소별 생성되는 지표이므로 같은 지표라 할지라도 거래소마다 다르게 나타날 수 있다. 제공된 데이터에서는 30여개의 각기 다른 마켓, 네트워크 지표와 거래소마다 수치가 다른 70여개의 지표가 주어졌다.

### 1-2. 환경

협업 환경: GitHub, Wandb

의사 소통: 카카오톡, Zoom, Slack

## 2. 프로젝트 팀 구성 및 역할

|     |                                       |
|-----|---------------------------------------|
| 공통  | Feature 분석 및 모델 개발                    |
| 곽정무 | 거래소 EDA 및 feature engineering         |
| 박준하 | Model 학습 검증 및 framework 개발            |
| 박태지 | Market data EDA                       |
| 신경호 | Hyperparameter tuning 및 visualization |
| 이효준 | Network data EDA                      |

## 3. 프로젝트 수행 절차

### 3-1. Timeline

(1주차) 강의 듣기

(2주차) EDA 피처 엔지니어링 및 모델 실험

(3주차) GitHub 활용 및 Wandb 활용 실험

### 3-2. 협업 과정

[1] EDA, Feature Engineering, Model, Hyperparameter tuning 별로 역할 분배

[2] 피어 세션 때 각자의 아이디어 공유 및 GitHub에 수행 결과 업로드

[3] 프로젝트를 모듈화 시켜 GitHub에 업로드

[4] 모듈 간 작동이 원활하지 않으면 이슈 탭을 통해 문제 해결

## 4. 프로젝트 수행 결과

### 4-1. EDA

모델을 통한 학습수행하기 전 가장 먼저 고려했던 부분은 거래소별 데이터를 포함하기에 같은 지표임에도 다른 수치를 가지는 피처들의 문제였다. 원본 데이터는 약 100여개의 피처들을 포함하고 있는데 거래소만 다른 지표들이 절반을 넘게 차지했다. EDA를 진행했을 때 거래소마다 다른 지표들이 등락률을 예측하는 데 유의미하다면, 학습 과정에 포함시켜야 되지만 거래소들의 평균과 예측하는 데 유의미한 차이가 없다면 학습에 들어가는 지표를 절반 이상 줄일 수 있었다.

따라서, 거래소별 다른 지표에 속하는 funding rates, open interest 등의 타겟 클래스별 통계량을 확인하고 등락률과의 상관관계를 계산해봤지만 거래소들의 평균과 유의미한 차이가 보이지 않아 모델 학습 과정에 포함하지 않기로 결정했다.

이후, 30여개 정도 되는 기본적인 지표들의 EDA를 마켓 지표와 네트워크 지표로 나눠 수행했다. 공통적인 분석 결과로 기본적인 지표는 타겟 클래스별로 그룹화하여 통계량을 비교했을 때 유의미한 차이가 나지 않는 경우가 대부분이었고 변동폭의 절댓값을 기준으로 나눌 수 있는 통계량이 추출되는 지표들이 있었는데 이는 금융 시장에서 등락이 심할 때와 등락이 심하지 않을 때 지표가 다르다는 도메인 지식과 일치했다.

### 4-2. 피처 엔지니어링

프로젝트를 시작할 때부터 추가적인 지표가 필요하다는 가설이 설정되었고 EDA결과로 해당 가설이 검증됐다. 가지고 있는 데이터셋이 시계열데이터인만큼 차분, 시프트, 이동평균과 같은 흐름을 반영하는 피처를 생성했다. 추가적으로 팀원들 모두 비트코인에 대한 도메인 지식이 깊지 않아 LLM을 활용해 매수와 매도에 대한 신호를 주는 파생 지표들을 피처 엔지니어링 과정에서 추가했다.

주어진 데이터셋에서 등락률과 연관성이 제일 높은 지표는 종가 가격이다. 하지만, 종가 가격이 제공되면 등락률을 직접 계산할 수 있어 정답을 알고 있는 것과 동일해 테스트

데이터셋에서는 제공되지 않았다. 이를 활용하려면 테스트 데이터셋에서의 가격을 추가로 예측해야 되기에 대회 초기에는 가격 데이터를 이용하지 않는 방식으로 진행했다. 그러나 데이터셋의 출처인 Cryptoquant의 유저 가이드를 통해 가격 지표를 활용해 만드는 파생 변수로 거래 포지션을 결정함을 확인하고 트레이닝 데이터셋에 가격 관련 파생 지표를 피처 엔지니어링 과정에서 포함시켰고 그 결과 총 1200개의 피처가 생성됐다. 모델은 크게 분류문제와 회귀문제로 나눠 진행했다. 분류 문제는 직접적으로 클래스를 예측하고 회귀 문제는 정확한 등락률을 예측하고 예측한 등락률로 클래스를 분류한다. 모델을 학습시키고 난 후 학습이 어떻게 되었는가에 대한 지표로는 대회에서 사용되는 accuracy 외에도 precision, recall, f1-score 등을 활용했고 confusion matrix를 시각화해 정확도 향상만을 보기보다 다양한 시각으로 접근하려 시도했다.

### 4-3. 모델별 분석

#### 1) Soft Labeling Model

##### 1-1) 문제 제기

주어진 문제는 multi-class classification으로, 등락 범위에 따라 0, 1, 2, 3으로 분류해야 한다. 하지만 이를 있는 그대로 분류 문제로 받아들이면 문제가 발생한다. 실수 범위의 등락 퍼센트를 binning하여 단순히 4개의 class로 변환하는 과정에서 정보의 손실이 불가피하게 발생한다는 것이다. 구체적으로, 0.4% 상승과 0.1% 상승을 예시로 들면 둘 다 0% ~ 0.5%에 해당하므로 class2에 속하지만, 각각 class1과 class3에 가깝다는 점이 다르다. 하지만 분류 문제에서는 이러한 세부 정보가 소실되고 모델은 데이터의 class가 2라는 점밖에 모른다.

이 단점을 극복하고자 등락 퍼센트를 직접 예측하는 회귀 문제로 변환해 접근해볼 수 있다. 하지만 이 역시 단점이 존재하는데, 회귀는 class의 경계에 집중하지 못하고 정확한 가격을 맞추려 한다는 것이다. 다시 말해, 회귀는 분류로 인해 소실된 정보에 불필요하게 과집중하는 문제가 발생한다. 그렇기에 결국, 해당 문제를 해결하기 위해서는 분류와 회귀 사이 어딘가 존재하는 모델의 필요성이 대두된다.

##### 1-2) 가설 제안

이를 해결하기 위해 데이터의 label을 smoothing하는 soft-labeling 방법을 고안했다. soft-labeling이란, label을 각각의 class에 대한 확률로 두어 각 데이터들의 label 분포를 부드럽게 하는 것이다. 예를 들어, +0.4%는 class2일 확률을 0.6, class3일 확률을 0.4로 둘 수 있고, +0.1%은 class1일 확률을 0.4, class2일 확률을 0.6으로 둘 수 있다. 이러한 방식으로 정보의 손실을 어느정도 완화하는 동시에 모델이 class의 경계에 집중할 수 있도록 한다. Soft-labeling의 적용을 정당화하기 위해 문제를 단순화하여 모델이 오직 class1과 class2, 즉 변동방향만을 예측하도록 했다. 그렇다면 soft-labeling을 아래와 같이 tanh함수로 구현할 수 있다.

$$label = \tanh(s \times (price\ change\ percentage)) : 수식\ 1$$

이때  $s$ 는 label의 sharpness를 결정하는 하이퍼파라미터로,  $s$ 가 커지면 문제가 분류에 가까워지고 반대로 작아지면 회귀에 가까워진다.  $\tanh$ 함수의 그래프를 생각해보면 쉽게 알 수 있다.  $s$ 가 매우 크다면 그래프가 좌우로 압축되어 price change percentage가 0에서 조금만 벗어나도 바로 label이 -1이나 1에 근사하는 값이 된다. 반대로  $s$ 가 매우 작다면 label은 price change percentage를 단순히 scaling한 값이 된다.  $\tanh$ 함수는 0근처에서  $y = x$ 와 근사하기 때문이다. 적절한 sharpness를 통해 계산된 label을 모델이 예측하도록 하면 최적의 label 표현이 되어 모델의 성능을 최대화할 수 있을 것이다.




Figure 1.  $\tanh(100 * X)$




Figure 2.  $\tanh(1 * X)$

### 1-3) 실험 결과

비교대상이 되는 베이스라인 모델은 가격의 변동을 label로 하는 단순한 회귀 모델이다. 또한 우리가 관심있는 label-smoothing을 적용한 모델은  $\tanh$ 함수를 통해 변환된 값을 label로 두는 회귀 모델이다. 두 모델 모두 단일 lightGBM 모델이며, 하이퍼파라미터는 아래와 같이 두었다.

표 1. Label smoothing 모델 하이퍼파라미터

|        | learning_rate | num_leaves | lambda_l1 | lambda_l2 | max_depth | extra_trees | path_smooth |
|--------|---------------|------------|-----------|-----------|-----------|-------------|-------------|
| values | 0.1           | 10         | 0.5       | 0.5       | 4         | True        | 0.5         |

모델의 정확도 평가는 k-fold validation( $k=4$ , shuffle=False)를 통한 accuracy로 진행했다. 이 경우, 베이스라인 모델은 0.519가 나왔으며 soft labeling model은 sharpness에 따라 아래 그래프와 같이 나왔다. 이때, sharpness는 0.1 단위로 증가시켜 50까지 탐색했다.




Figure 3. Soft Labeling Model Accuracy

그래프로부터 sharpness에 따른 accuracy가 대략 7부근까지는 급격하게 상승하지만, 이후로는 0.54 ~ 0.55근처를 유지한다는 점을 알 수 있다. sharpness를 극단적으로 크게 조정해도 이 부근의 accuracy가 나왔다. 이는 현재 풀고 있는 문제에서 분류로 손실되는 정보보다는 class의 경계에 집중하는 것이 훨씬 더 중요하다는 것을 의미한다. 실제로, 팀 내에서 이루어진 다양한 시도들에 대해 회귀보다 분류로 문제에 접근하는 방식이 전반적으로 더 좋은 성능을 보였다.

## 2) Voting Model

### 2-1) 문제 제기

암호화폐 시장에서 가격 변동성은 매우 크며, 투자자와 거래소는 이러한 변동성을 예측 하는데 어려움을 겪는다. 따라서 이 프로젝트의 주된 문제는 다음과 같다.

비트코인 거래에서 발생하는 극단적인 가격 변동(0,3)과 보통의 가격 변동(1,2) 사이의 분류 문제는 클래스 간의 불균형을 초래하며, 이로 인해 예측 성능이 저하될 수 있다. 이러한 불균형 문제는 예측 모델이 클래스에만 집중하는 경향을 띄게 하며, 이는 모델 예측에 매우 부정적인 영향을 미칠 수 있다.

암호화폐 시장의 가격 변동에는 수많은 변수들이 영향을 미치며 서로 다른 특성이 다양한 방식으로 상호작용한다. 단일 모델이 모든 변수와 그들 간의 상호작용을 효과적으로 학습하고 다룰 수 있는지에 대한 의문이 제기될 수 있다.

### 2-2) 가설 제안

불균형 클래스 문제는 각 클래스의 빈도를 반영한 동적 클래스 가중치로 해결할 수 있다. 클래스 가중치를 적용함으로써, 모델이 소수 클래스에 대해서도 균형 있게 학습할 수 있으며, 이를 통해 전반적인 성능 향상이 이루어질 것으로 가정했다. 특히, 트리 기반 모

델에서 이러한 가중치 적용은 예측 성능에 긍정적인 영향을 미칠 것으로 예상된다. LightGBM과 XGBoost 모델은 서로 다른 강점을 가지고 있는 부스팅 기반 모델이다. LightGBM은 데이터셋 크기와 처리 속도에서 뛰어나고, XGBoost는 더 정교한 트리 구조를 학습할 수 있는 장점이 있다. 두 모델을 결합한 Voting Classifier를 적용하면 각 모델의 장점을 결합해 더 높은 성능을 기대할 수 있다. 또한, soft voting 방식은 모델이 각 분류에 대한 확률을 기반으로 결정하므로, 더 안정적이고 일관된 결과를 도출할 수 있다. 0과 3, 1과 2로 그룹을 나눈 후, 각 그룹내에서 세부 분류를 수행하는 방식으로 진행하여 극단적인 가격 변동과 보통의 가격 변동의 차이를 활용한 다단계 분류 전략을 진행했다. 이 전략은 더 세밀한 분류를 할 수 있으며, 더 나은 성능을 보일 것이다.

### 2-3) 실험 결과

평가 방식은 Accuracy, 즉 2024년 1월부터 4월까지의 전체 샘플에서 1시간 뒤 등락률을 0, 1, 2, 3이라는 4개의 레이블 중 정확하게 예측한 샘플의 비율로 계산됐고 최종 점수는 0.4090을 달성했다.

### 4-4. 하이퍼파라미터 튜닝

모델을 학습시킬 때 하이퍼파라미터를 조정할 수 있으며 파라미터에 따라서 모델의 성능이 좌우된다. 그 중 위 대회에서 사용하는 지표인 accuracy가 가장 높은 하이퍼파라미터를 구하기 위하여 시각화에 강점을 지닌 최적화 도구인 wandb를 사용했다.

Soft-voting 기법을 사용하므로 각 모델에 대한 파라미터를 sweep\_config 변수에 저장한 후 최적화를 진행했다. 아래의 그림은 하나의 모델에 대한 hyper parameter 분석 중 일부로 random하게 feature를 추출하여 실험한 결과 최종적으로 약 0.401의 accuracy를 가지는 하이퍼파라미터를 도출했다.




Figure 4. 하이퍼파라미터 튜닝

시각화를 통해 확인한 결과 hyper parameter tuning 과정에서 모델의 성능을 향상시킬 수 있었다.

## 5. 자체 평가

### 5-1. 데이터가 원시적이다.

데이터 구조가 복잡하고 결측치와 노이즈가 포함되어 데이터를 분석 가능한 형태로 전처리하는데 시간이 소요됐다. 더 정제된 데이터를 사용할 수 있거나, 추가적인 데이터를 사용할 수 있었다면 모델 성능 향상에 더 기여할 수 있었을 것이다. 이 과정에서 결측치 처리, 이상치 제거 등 데이터를 다루는 방법론에 대한 귀중한 경험을 쌓을 수 있었다.

### 5-2. 팀원 간의 협업이 너무 늦게 진행되었다.

프로젝트 초반에 팀원 간의 협업이 원활하지 않았던 점은 이번 프로젝트의 약점이었다. 개별적인 데이터 분석 및 모델링 작업이 각기 다른 방향으로 진행되면서 프로젝트의 흐름이 분산되었고, 이를 통합하는 데 많은 시간이 소요되었다. 하지만 프로젝트 중반 이후부터 GitHub를 적극적으로 활용하면서 팀원 간의 협업이 강화되었고 이를 바탕으로 데이터 처리 방식과 모델 성능 개선에 긍정적인 영향을 미쳤다. 이러한 협업 툴을 프로젝트 초반부터 효과적으로 활용했다면, 아이디어와 전략이 조율이 가속화되어 프로젝트의 완성도를 높이는 데 큰 도움이 되었을 것이다.

### 5-3. 명확한 계획을 수립하지 않고 시작했다.

명확한 계획을 수립하지 않고 프로젝트를 시작했다. 사전에 GitHub 강의나 관련 자료를 학습하지 않고 사용하다 보니 초기에 협업이 원활하지 않았다. 또한, 프로젝트의 각 단계에서 충분한 시간을 두지 않고 결과를 빠르게 얻고자 조급해졌다. 이러한 문제점은 프로젝트의 전반적인 퀄리티를 낮췄다. 이 경험을 통해 충분한 사전 학습과 계획 수립의 필요성을 느꼈으며, 인내심을 가지고 각 단계를 진행하는 것이 중요하다는 교훈을 얻었다.

### 5-4. 실무와 다른 접근 방식으로 진행했다.

실무에서 해당 프로젝트를 진행한다고 했다면 등락률과 가장 연관성이 높은 가격변수를 예측하는 분석부터 진행했을 텐데 가격 예측을 하지 않았기에 정확도가 낮아 서비스를 제공하기 어려웠다. 또한 가장 중요한 피처인 가격이 제외되었기에 다소 한정적인 분석을 진행할 수밖에 없었다. 이를 통해 다음 프로젝트부터는 '대회를 실무에 대입하여 실무와 가까운 분석을 진행하는 경험을 쌓자'라는 방향성을 가질 수 있었다.

### 5-5. 협업 툴에서의 부족함이 보였다.

GitHub을 활용하는 측면에서 익숙하지 않은 모습을 보였다. 중반부부터는 GitHub에 적응하는 모습을 보였지만 GitHub만을 이용하다 보니 회의록을 작성하거나 가설 및 검정을 기록하는 과정에서 아쉬움이 나타났다. 앞으로 Notion이나 Jira를 활용하여 프로젝트 전반의 흐름과 내용을 기록한다면 프로젝트를 보다 효과적으로 진행할 수 있을 것이다.

## 개인 회고 (곽정무\_T7504)

이번 프로젝트는 부스트캠프에 처음 들어와서 해본 대회였기에 진행하면서 많은 어려움과 애로사항이 따랐던 것 같습니다. 이 부분들에 대해 개인 회고록에 허심탄회하게 풀어보고자 합니다.

처음에 대회에 들어갈 때는 높은 순위를 목표로 하고 협업이라는 부분은 뒤로 미뤄졌었습니다. 그 결과, 팀원들이랑 합의한 부분은 추석이 끼어 있기 때문에 추석 연휴 기간 동안 각자 대회에 몰두하기 위해 일단 수업을 빨리 듣는 걸 목표로 했으나, 정작 협업을 크게 끌어 올릴 수 있는 깃허브 특강 강의가 필수 강의를 아니라는 이유로 다들 무시하고 넘어갔고 이는 대회 막바지에야 서로 깨닫고 부랴부랴 깃허브를 관리한게 기억에 남습니다.

다행히도, 막바지에야 대회 점수에 집착하지 말고 대회를 통해 무엇을 얻어가는지 집중하라는 오피스아워 조언을 듣고 팀원들과 상의를 거쳐 빠르게 점수 중심에서 협업 중심으로 넘어 갔던 점은 만족스러웠습니다. 따라서, 막바지에 시간이 많지 않음에도 불구하고 점수 올리기에 집중하기 보다는 다 같이 깃허브 강의를 듣고 강의의 github convention을 따라 체계적으로 결과물을 정리하는데 집중하는데 많은 시간을 할애했습니다.

개인적인 대회를 위한 학습으로는, 저는 아무래도 도메인 지식을 분석에 적극 활용하는 걸 선호하는데 비트코인은 경험이 전혀 없어 LLM을 적극적으로 활용했고 데이터셋의 레퍼런스 사이트인 크립토퀀트도 찾아보고 유튜브에서 회사 대표가 나와 인터뷰하는 영상도 보면서 부족한 도메인 지식을 메우는데 개인적으로 집중했습니다.

모델 개선에는 다른 팀원들에 비해 쌓은 지식을 활용한 피쳐 엔지니어링에 집중했습니다. 하지만, 데이터셋에 포함되지 않은 피쳐들이(ex) MVRV) 도메인에서 핵심적임을 깨닫고 매우 아쉽기도 했고 실제 성능 향상은 많이 이루어지지 않았습니다. 또한, 모델에서 일어나는 필수적으로 해결되어야 되는 요소들을 파악하는데 주력했습니다. 저는 두가지를 크게 뽑았는데 클래스 불균형으로 0과 3의 비율이 너무 적어 모델이 1과 2로만 예측한다는 측면과 confusion matrix를 그려서 결과를 확인해 봤을 때 1과 2로 예측하더라도 recall이 두 카테고리에서 0.5 언저리에 불과해 당장 가격이 오를지 내릴지 구분을 못한다는 점이었습니다. 클래스 불균형은 SMOTE 같은 오버 샘플링을 써도 성능이 내려갈



뿐 효과가 없었습니다.

따라서 저는 모델을 단순히 변경하는 것으로는 충분치 않다고 생각했고 의미 있는 피처를 입력으로 사용하는데 치중했습니다. 그러나, 모든 시도들은 실패에 그쳤고 따라서 다시 EDA를 진행한 뒤에 등락률을 예측하는 데 핵심적인 요소인 가격이 주어진 피처들과 상관관계가 높다는 것을 발견하고 활용할 방안을 생각했지만 학습 방식에 대해 고민하다 대회가 끝났습니다.

결론적으로, 문제점 인식 파악에는 성공했지만 실질적인 성능 향상은 이뤄내지 못했으나 이번 대회를 치르면서 대회와 실무의 큰 간극을 인식했습니다. 실제 상황에서는 몇 천개의 등락률을 예상할 일은 없고 비효율적입니다. 그리고, 학습 또한 몇 천개를 진행하기 보다는 비트코인 시장이 24시간 열려 있고 기존의 주식 시장보다 변동성이 큰 시장임을 고려하면 빠른 판단이 중요하여 적은 샘플만 사용하여 당장 미래의 1시간을 예측하는게 중요하다고 생각하고 현재 가격 데이터 또한 피쳐로 활용할 수 있습니다.

이번 대회에서는 성능만을 따졌을 때는 성공이라 부를 만한 지점은 없었고, 특히나 실제 서비스 활용이라 생각한다면 accuracy 가 0.4 인 서비스를 활용할 고객은 존재하지 않을 것입니다. 그러나, 많은 교훈은 얻어가는 대회라 생각합니다. 특히나, LLM을 처음으로 적극적으로 활용해 보았는데 효율에서 우수성을 알 수 있었고 앞으로도 LLM을 활용하여 일의 능률을 늘릴 수 있습니다. 그리고, 협업을 등한시한 별로 대회 막바지에 오히려 스퍼트를 내지 못했는데 다음 대회부터는 대회 진입 전에 크게 개괄적인 요소를 정리하여 팀원들의 아이디어를 계속 추적하며 짜임새 있게 대회를 진행하고 싶습니다.

대회와 실무의 간극 또한 인식을 했으나 실제 서비스로 어떻게 구체적으로 개발할지에 대해서 고민이 충분치 않았습니니다. 실무 경험이 없어 현실적인 판단을 내릴 수 있겠지만 실제 서비스에 어떻게 활용할 수 있을지 고민하는게 우선적으로 제가 대회를 통해 가져가야 되는 부분이고 고민을 통해 실제 서비스에 활용될 수 있는 프로덕트 또한 간단하게 만들어 보고 싶습니다.

## 개인 회고 (박준하\_T7523)

비트코인 가격 예측 프로젝트를 처음 접했을 때, 한가지 의문이 떠올랐습니다. 프로젝트가 등락폭에 대한 직접적인 회귀문제가 아니라 등락폭을 binning하여 만든 클래스를 예측하는 분류 문제였기 때문입니다. 저는 문제를 주어진 대로 분류문제로 접근하면 binning 과정에서 가격 정보의 손실이 일어나고 이것이 모델 학습에 악영향을 끼칠 것이라는 가설을 세웠습니다. 하지만 정보 손실을 막기 위해 회귀로 접근방식을 변경했을 때, 오히려 성능이 저하되는 현상이 나타났습니다. 이로부터 회귀 모델은 모델이 클래스의 경계에 집중하지 못하여 정확도가 낮다고 추측하였고, 결국 분류와 회귀 모델의 장단점을 조율한 모델의 필요성을 느꼈습니다.

이를 해결하기 위해 저는 모델에 soft-labeling 기법을 도입하였습니다. Soft-labeling을 사용하면 분류 모델의 장점을 유지함과 동시에 label이 확률로써 나타나지면서 정보 손실을 완화할 수 있을 것이라 생각했기 때문입니다. 저는 최적의 softness를 찾기 위해 softness에 따른 모델의 정확도를 계산하였고, 그 결과 label이 단순히 hard해질수록, 즉 문제가 단순 분류에 가까워질수록 정확도가 높아진다는 결과를 얻었습니다. 이로부터 binning 과정에서 발생하는 정보 손실은 이번 프로젝트에서 크게 중요하지 않다는 결론을 내렸습니다. 비록 분류와 회귀 모델의 장점을 조합해 성능 향상을 이룬다는 목표는 달성하지 못했지만, 가설을 세우고 검증하는 과정을 반복함으로써 논리적인 사고를 발전시킬 수 있었던 좋은 경험이었습니니다.

프로젝트를 진행하면서 눈여겨본 또다른 문제점은 바로 데이터의 부족입니다. 특히 +0.5% 이상 상승과 -0.5% 이하 하락과 같은 극단적인 변동에 대한 데이터가 부족해 클래스 불균형이 생겼던 점이 문제였습니다. 저는 이를 해결하기 위해 다양한 데이터 증강 기법들을 시도하였습니다. 대표적인 SMOTE는 물론, tsaug 패키지를 이용해 time warping, 추세 추가 등 다양한 시계열 증강 기법들도 시도해보았으나, 아쉽게도 유의미한 성과는 거두지 못했습니다. 워낙 데이터가 적어 증강된 데이터 역시 class의 분포를 제대로 나타내지 못했을 거라 추정됩니다.

그러나 저는 여기서 멈추지 않고 데이터의 부족을 극복할 또다른 방안을 모색하였습니다. 이에 얼마 전 과제에 등장한, LLM 기반 zero-shot 추천에서 영감을 받아 LLM의 미리 훈련된 가중치가 데이터 부족을 해결하는 열쇠가 될 수 있지 않을까 생각했습니다. LLM의 방대한 parameter에 비트코인 관련 feature들의 의미가 내포되어 있을 것이라고 생각한 것입니다. 따라서 hugging face에서 사전 학습된 모델을 가져와 프로젝트에 맞게 fine-tuning을 시도하였습니다. 하지만 모델은 기대와 달리 전혀 학습되지 않았습니다. 아마도 사용한 모델의 주 목적이 text classification이기에 복잡한 정형데이터의 관계를 모델링하기에는 부적합했던 것으로 보입니다. 비록 실패한 접근이었지만, 하나의 문제를 끈기 있게 해결하려는 도전과 함께, 기존의 틀을 벗어나 새로운 방법을 시도해본 즐거움

경험이었습니다.

이번 프로젝트는 이렇게 실패의 연속이었지만, 실패보다 더 아쉽게 느껴졌던 두 가지 점이 있습니다. 첫째로, EDA를 처음에 진행하지 않았던 것입니다. 데이터에 대한 충분한 이해 없이 모델링을 시작하다 보니, 모델이 어떤 성능을 내더라도 그 결과를 데이터의 관점에서 분석하기가 어려웠습니다. 이는 모델 성능의 해석과 개선에 큰 제약이 되었습니다. 둘째로, 팀원 간의 협력이 부족했던 점입니다. 서로의 모델과 아이디어를 더 적극적으로 공유했다면, 더 효율적으로 프로젝트를 진행할 수 있었고, 더 나은 아이디어가 나왔을 것이라고 생각합니다. 협력의 중요성을 간과한 것이 큰 아쉬움으로 남았습니다.

이러한 한계점을 인식하고, 다음 프로젝트에서는 충분한 EDA와 적극적인 협력을 통해 보다 성공적인 결과를 이루겠다고 다짐합니다.

## 개인 회고 (박태지\_T7524)

이번 프로젝트는 비트코인 가격 예측 모델을 개발하는 과정에서 다양한 기법과 도구를 활용하면서 많은 경험을 할 수 있었습니다. 하지만 몇 가지 아쉬운 점들이 있었고, 이를 통해 배운 점들을 바탕으로 더 나은 방법론을 고민하게 되었습니다.

### 1. 데이터 처리와 전처리 단계의 어려움

데이터 전처리 과정에서 결측치 처리 방법과 비정상적 분포를 가진 데이터를 다룰 때 더 철저한 분석과 처리가 필요했습니다. 코인 데이터 특성 상, 극단적인 값이 중요한 피처일 수도 있지만 제대로 처리하지 못한 것이 모델 성능에 악영향을 미친 것으로 보여집니다. 다음 프로젝트에서는 데이터의 분포를 사전에 확실하게 분석하고, 도메인 지식을 활용한 처리를 고민할 필요가 있다고 생각합니다.

### 2. 불균형 데이터 처리의 한계

클래스 불균형 문제는 분류 문제에서 중요 요소입니다. 데이터 특성상 극단적인 값의 비율이 많이 작기에 주요 도전 과제입니다. SMOTE, undersampling 등의 기법을 적용했지만, 성능 개선이 제한적이었습니다. 이에, 클래스 가중치 설정을 통해 더 정교한 방법들을 고려했습니다. 1,2 클래스는 7215개, 0,3 클래스는 1545개 이기에, 가중치를 1,21, 5,67을 주고 진행을 하였습니다. 그 결과, 0(1,2클래스)의 Precision은 0.83, 1(0,3클래스)의 Precision은 0.21로 제대로 분류가 되지 않았습니다. 데이터의 불균형을 근본적으로 해결하지 못한 점이 아쉬웠습니다.

### 3. 모델 선택 및 앙상블 모델의 성능

앙상블 기법을 적용하여 모델 성능을 개선하고자 하였으나, Voting Classifier를 통한 앙상블 전략에서 기대했던 만큼의 성능 향상을 거두지 못했습니다. 개별 그룹의 분류에서 모델의 개별 성능 차이가 크지 않았습니다. 0,3 클래스 분류에서 Precision은 각각 0.51, 0.54 이였고. 1,2 클래스 분류에서 Precision은 0.51, 0.53이였습니다. 다중 모델을 결합한 것이 오히려 성능을 저하시킬 수 있다는 사실을 경험하게 되었습니다. 모델 선택에서 더 많은 실험과 튜닝이 필요했고, 다양한 모델 조합을 충분히 고려하지 못한 점이 아쉬웠습니다.

#### 4. 모델 성능 평가의 한계

Confusion Matrix에서 성능이 고르지 못하게 나왔습니다. 특히 1과 2 클래스에서 예측 성능이 불균형하게 나왔고, precision과 recall 모두 낮은 점수에 그쳤습니다. 성능 평가에서 단순한 정확도뿐만 아니라 다양한 지표를 고려해 모델을 개선해야 한다는 점을 깨닫았습니다.

#### 5. 협업 및 GitHub 활용

프로젝트 초반부에 GitHub을 통한 협업을 제대로 활용하지 못해 팀원 간의 코드 관리를 체계적으로 수행하지 못한 점이 매우 아쉬웠습니다. 프로젝트 후반부에야 GitHub을 도입해 작업을 병합하고 관리하였으나, 초기에 도입했더라면 활발한 아이디어 공유와 코드 관리가 가능했을 것입니다. 이번 프로젝트를 통해 GitHub와 같은 협업 도구를 프로젝트 초반부터 적극적으로 활용하는 것이 중요하다는 교훈을 얻었습니다.

#### 6. 비트코인 도메인 지식의 부족

프로젝트를 진행하며 비트코인, 블록체인 도메인에 대한 깊은 이해가 부족했습니다. 데이터 분석과 모델링 자체는 어느 정도 해결할 수 있지만, 코인 시장의 특성과 주요 변수들이 의미하는 바를 충분히 이해하지 못한 상태에서 모델링을 진행하다 보니, 중요한 피처를 놓치거나 부정확한 가정을 하게 된 경우가 있다고 생각합니다. 향후에는 도메인 지식을 확장시켜 프로젝트의 효율성을 높일 필요가 있다고 느꼈습니다.

## 개인 회고 (신경호\_T7530)

### 1. 목표를 달성하기 위한 노력

- 데이터에 대한 이해
  - 정확도를 높이기 위해서는 주어진 data에 대한 이해가 중요하다고 생각하였습니다. 이를 위해 각 feature가 표현하는 값을 이해하려고 노력하였습니다. 또한 의미있는 파생변수를 발굴하기 위하여 LLM모델을 사용하였습니다.
- EDA 및 실험
  - Feature engineer를 통하여 새로운 파생 변수들을 생성하고 EDA로 검증을 진행하였습니다. 또한 정확도를 높이기 위해 soft-voting 앙상블을 통하여 모델을 학습시켰습니다.
- 하이퍼 파라미터 분석
  - Wandb를 이용하여 하이퍼 파라미터 최적화를 진행하였습니다.

### 2. 마주친 한계, 아쉬운 점

- 과적합 문제
  - 주어진 train data에는 0과 3을 합쳐서 약 20%, 1과 2는 각 40%의 비율을 지니고 있었습니다. 이런 class 불균형을 해결하기 위하여 SMOTE 등 데이터 증강 기법을 사용하였지만 성능이 더 낮게 나왔습니다. 마지막 모델에서는 이런 문제를 해결하지 못하였다는 아쉬움이 남았습니다.
- 충분하지 못한 도전
  - 개인적으로 diff와 mean같은 통계함수와 다른 feature들의 조합을 이용하여 많은 도전을 하였다고 생각했지만 팀원 및 마스터 클래스에서 발표한 다른 팀과 비교하여 너무 무난한 시도였다고 생각하였습니다.

### 3. 다음 프로젝트에 시도하고 싶은 점

- 데이터 연관성 분석
  - 마스터 클래스에서 말씀하신 feature들의 연관성 및 중요도를 분석하는 tool을 말하셨는데 다음번에는 이를 적용하여 프로젝트에 적용하고 싶습니다.

## 개인 회고 (이효준\_T7545)

이번 프로젝트의 목표는 강의에 포함된 툴들을 활용하여 실무와 가까운 결과물을 도출하는 것과 GitHub을 이용해 협업 경험을 쌓는 것이었다. 이를 위해 Timeline을 설정하여 선행적으로 강의를 학습하고 LightGBM 논문을 읽으며 베이스라인 코드의 작동원리를 이해했다. 추가적으로 XGboost를 학습하며 두 모델의 차이점을 기반으로 실험을 진행했다.

이후에는 도메인지식의 부족을 인지하고 EDA에 집중했다. 이를 통해 등락과 변동폭에 다른 변수가 영향을 미친다는 가설을 세우고 이를 검증하기 위해 등락과 변동폭을 각각 모델링하고, 두 결과를 결합하는 앙상블 기법을 사용했다. 또한, 스택킹 앙상블을 활용해 각 예측을 결합하여 모델을 개선했으나, 과적합과 클래스 불균형 문제가 발생했다. 이를 해결하기 위해 SMOTE, 언더샘플링같은 샘플링 기법을 도입하고, 모델 구조를 변경했다.

이번 프로젝트를 통해 복잡한 상관관계를 가진 데이터를 앙상블 기법으로 해결하는 방법을 학습하며 과적합 문제에 대한 해결책을 모색했다. 또한 클래스 불균형 문제를 해결하기 위해 앞서 언급한 기법 외에도 정밀도, 재현율 등 여러 지표를 사용하며 다양한 해결방안을 모색했다. 이러한 경험은 이후 프로젝트에도 큰 도움이 될 것이다.

GitHub을 활용한 협업이 이번 프로젝트에서 큰 변화를 가져왔다. 체계적인 협업과 분업이 가능했으며, 팀원들과의 소통이 더 원활해졌다. 또한 프로젝트를 진행하는데 있어 조직적이고 계획적으로 문제를 해결할 수 있었다.

프로젝트 초반, EDA 과정에서 제한된 가설을 설정한 탓에 하나의 인사이트에 몰입해 시계열 분석이나 회귀분석, 가격예측을 통한 타겟값 예측 등 여러 모델과 가설에 대한 시도를 하지 못했다. 이 경험을 토대로, 추후에는 다양한 모델링 기법과 피처 엔지니어링 기법을 활용하여 폭넓은 시각과 관점을 가질 수 있도록 더욱 노력할 것이다.

협업 과정에서 초반에는 체계적으로 가설 정리와 분업이 이루어지지 못한 점이 아쉬웠다. 각자 프로젝트를 진행하며 진행상황에 대한 기록이 부족하여 협업의 효율성을 떨어졌기에 추후에는 Jira와 같은 툴을 활용하여 프로젝트의 흐름을 기록 및 공유하고 킥오프 미팅을 비롯한 주기적인 미팅을 도입해 커뮤니케이션 시스템을 구축할 계획이다.

GitHub에 대한 부족한 이해와 가설의 코드구현이 한계로 작용했다. GitHub에 대한 이해가 충분했다면 초반부터 협업이 가능했을 것이며, 가설 구현이 빨리 이루어졌다면 다른 가설들을 실험할 여유가 있었을 것이다. 이를 해결하기 위해 추가적인 강의를 통해 GitHub 심화학습을 진행하고 ChatGPT같은 AI의 효과적인 활용방안을 모색할 예정이다.

이 경험을 발판삼아, 앞으로는 보다 체계적이고 효과적으로 문제를 해결할 수 있을 것이라는 자신이 생겼다. 제너럴리스트의 관점에서 폭넓은 시야를 가지고 다양한 시도를 통해 학습한 내용을 기반으로 더 나은 성과를 창출할 것이다.